

Algoritmo EM

Por conveniencia para el lector y para nosotros, plantearemos el problema desde el principio para no perder el hilo:

Se pretende identificar de qué gaussiana proviene una muestra concreta de un conjunto de muestras

$$X = \{x_1, x_2, \dots, x_N\}$$

que ha sido obtenida de un modelo muestra de K gaussianas. Para ello, se introducen las variables latentes

$$z_n \in \{1, 2, \dots, K\}$$

que indican de qué componente proviene una observación x_n . Planteamos el modelo generativo de la forma

$$P(x_n | z_n = k; \theta) = \frac{1}{(2\pi)^{(\frac{D}{2})} |\Sigma|^{1/2}} \exp\left[-\frac{1}{2}(x_n - \mu_k)^T \Sigma_k^{-1} (x_n - \mu_k)\right]$$

donde θ representa al espacio de parámetros

$$\theta = \{\mu_k, \Sigma_k, \pi_k\}_{k=1}^K$$

Además, asume un prior sobre la variable latente:

$$P(z_n = k | \pi) = \pi_k, \quad \sum_{k=1}^K \pi_k = 1$$

Al tratar de maximizar la verosimilitud, obtendríamos el logaritmo de una suma. Se puede demostrar que esto no tiene solución analítica cerrada, por lo que se diseñó el algoritmo EM que rodea el problema precisamente introduciendo estas variables latentes Z y trabajando con la verosimilitud conjunta $P(X, Z | \theta)$. La idea es introducir una distribución auxiliar $q(z)$ sobre las variables latentes y descomponer su log-verosimilitud:

$$\begin{aligned} \log P(X | \theta) &= \log \int P(X, Z | \theta) dZ = \log \int q(Z) \frac{P(X, Z | \theta)}{q(Z)} dZ \stackrel{\text{def}}{=} \\ &\stackrel{\text{def}}{=} \log \mathbb{E}_{q(z)} \left[\frac{P(X, Z | \theta)}{q(z)} \right] \stackrel{\text{def}}{=} \mathbb{E}_{q(z)} \left[\log \frac{P(X, Z | \theta)}{q(z)} \right] + KL(q(z) || P(Z | X, \theta)) \end{aligned}$$

(ELBO + Divergencia Kullback-Leibler)

Maximizar el ELBO respecto de q es equivalente a minimizar la divergencia de Kullback-Leibler respecto de q . Ese mínimo se encuentra en $q(z) = P(Z|X, \theta)$. En ese punto, el ELBO coincide exactamente con $\log P(X|\theta)$. Es aquí donde entra el algoritmo EM (expectation-minimization) ([3] Bishop, C. M. (2006)):

Expectación:

En este paso el objetivo es calcular las responsabilidades de cada componente k sobre cada muestra x_n . Para ello, supondremos que las muestras son independientes e idénticamente distribuidas (iid) y entonces:

$$q(z) = P(Z|X, \theta) = \prod_{n=1}^N P(z_n|x_n, \theta)$$

Y ahora aplicando el Teorema de Bayes, calculamos para cada muestra cual es su probabilidad para cada componente k . Para eso, usaremos el prior categórico supuesto al principio:

$$P(z_n = k|x_n, \theta) = \frac{\pi_k \mathcal{N}(x_n|\mu_k, \Sigma_k)}{\sum_{k'=1}^K \pi_{k'} \mathcal{N}(x_n|\mu_{k'}, \Sigma_{k'})}$$

Y llamaremos a esto r_{nk} , que puede ser interpretado como la probabilidad de que la muestra x_n provenga de la componente gaussiana k . Lógicamente $\sum_k r_{nk} = 1$ para cada n ([3] Bishop, C. M. (2006)).

Minimización:

Es en este paso del algoritmo donde podemos responder a la pregunta planteada, acerca de por qué usaremos distribuciones de la familia exponencial para la estimación de los parámetros. En cada paso se actualizan los parámetros. La idea es que, habiendo fijado $q(z) = P(Z|X, \theta)$, $\log(P(X|\theta) = ELBO)$, por lo que bastaría con maximizar el *ELBO* con respecto a θ en la iteración i , que denotaremos por $\theta^{(i)}$ obteniendo un θ actualizado, que denotaremos por $\theta^{(i+1)}$. Para maximizar el *ELBO*, en este paso, $q(z)$ ya es fija. Entonces:

$$ELBO = \mathbb{E}_{q(z)}[\log \frac{P(X, Z|\theta)}{q(z)}] = \mathbb{E}_{q(z)}[\log P(X, Z|\theta)] + \mathbb{E}_{q(z)}[-\log q(z)]$$

Que es equivalente a maximizar $\mathbb{E}_{q(z)}[\log P(X, Z|\theta)]$, puesto que $\mathbb{E}_{q(z)}[-\log q(z)]$ no depende de θ . Y podemos escribir esto en términos de las responsabilidades r_{nk} :

$$\mathcal{Q}(\theta) = \mathbb{E}_{q(z)}[\log P(X, Z|\theta)] = \sum_{n=1}^N \sum_{k=1}^K r_{nk} [\log(\pi_k) + \log \mathcal{N}(x_n|\mu_k, \Sigma_k)]$$

Como la gaussiana pertenece a la familia exponencial, su log tiene la forma:

$$\log \mathcal{N}(x_n | \mu_k, \Sigma_k) = \log h(x_n) + \eta_k^T T(x_n) - A(\eta_k)$$

En concreto, pertenece con los siguientes parámetros (parámetros naturales, estadísticas suficientes y función de partición) ([4] Wainwright, M. J., & Jordan, M. I. (2008)):

$$\eta_k = \begin{pmatrix} \Sigma_k^{-1} \mu_k \\ -\frac{1}{2} \Sigma_k^{-1} \end{pmatrix}, \quad T(x_n) = \begin{pmatrix} x_n \\ x_n x_n^T \end{pmatrix}, \quad A(\eta_k) = \frac{1}{2} \mu_k^T \Sigma_k^{-1} \mu_k + \frac{1}{2} \log |\Sigma_k|$$

Por tanto, sustituyendo estos parámetros en $\mathcal{Q}$ obtendremos:

$$\mathcal{Q}(\theta) = \sum_{n=1}^N \sum_{k=1}^K r_{nk} [\log(\pi_k) + \log h(x_n) + \eta_k^T T(x_n) - A(\eta_k)]$$

El objetivo es encontrar los parámetros π_k , μ_k y Σ_k óptimos. Para ello, bastaría con derivar con respecto de η_k . Encontraremos primero la solución para π_k y posteriormente para μ_k y Σ_k :

$$\begin{aligned} \mathcal{Q}(\theta) &= \sum_{k=1}^K \sum_{n=1}^N r_{nk} [\log(\pi_k) + \log(h(x_n)) + \eta_k^T T(x_n) - A(\eta_k)] \\ &= \underbrace{\sum_{n=1}^N \sum_{k=1}^K r_{nk} \log \pi_k}_{\mathcal{Q}_\pi} + \underbrace{\sum_{n=1}^N \sum_{k=1}^K r_{nk} [\log h(x_n) + \eta_k^T T(x_n) - A(\eta_k)]}_{\mathcal{Q}_{\mu, \Sigma}} \end{aligned}$$

Maximización de los parámetros π_k

$$\mathcal{Q}_\pi = \sum_{n=1}^N \sum_{k=1}^K r_{nk} \log \pi_k, \quad \sum_k \pi_k = 1$$

Introducimos el multiplicador de Lagrange para este problema:

$$\mathcal{L}(\pi, \lambda) = \sum_{n=1}^N \sum_{k=1}^K r_{nk} \log \pi_k - \lambda \left(\sum_{k=1}^K \pi_k - 1 \right)$$

Derivando e igualando a cero (condición de óptimo local):

$$\nabla_{\pi_k} [\mathcal{L}(\pi, \lambda)] = \frac{\sum_{n=1}^N r_{nk}}{\pi_k} - \lambda = 0 \implies \pi_k^* = \frac{N_k}{\lambda}$$

Y como sabemos que:

$$\sum_{k=1}^K \frac{N_k}{\lambda} = 1 \implies \lambda = \sum_{k=1}^K N_k = N$$

Y por tanto:

$$\boxed{\pi_k^* = \frac{N_k}{N}} \quad (\text{trivial})$$

Maximización de los parámetros μ_k, Σ_k

Por sencillez, podemos maximizar η_k de forma equivalente a maximizar μ_k, Σ_k de forma conjunta, puesto que, recordamos que:

$$\eta_k = \begin{pmatrix} \Sigma_k^{-1} \mu_k \\ -\frac{1}{2} \Sigma_k^{-1} \end{pmatrix}$$

Por lo tanto, sabiendo que $\mathcal{Q}_{\mu_k, \Sigma_k}$ es:

$$\begin{aligned} \mathcal{Q}_{\mu, \Sigma} &= \sum_{n=1}^N \sum_{k=1}^K r_{nk} [\log h(x_n) + \eta_k^T T(x_n) - A(\eta_k)] = \\ &= \sum_{n=1}^N \sum_{k=1}^K r_{nk} [\log h(x_n)] + \sum_{k=1}^K \left(\eta_k^T \sum_{n=1}^N r_{nk} T(x_n) - N_k A(\eta_k) \right) \end{aligned}$$

Derivando con respecto a η_k e igualando a cero:

$$\begin{aligned} \nabla_{\eta_k} [\mathcal{Q}_{\mu, \Sigma}] &= \sum_{n=1}^N r_{nk} T(x_n) - N_k \frac{\partial A(\eta_k)}{\partial \eta_k} = 0 \\ \iff \frac{\partial A(\eta_k)}{\partial \eta_k} &= \frac{\sum_{n=1}^N r_{nk} T(x_n)}{N_k} \end{aligned}$$

Para cualquier función de la familia exponencial se verifica que ([4] Wainwright, M. J., & Jordan, M. I. (2008)):

$$\frac{\partial A(\eta_k)}{\partial \eta_k} = \mathbb{E}_{P(x|\eta_k)} [T(x)] = \frac{\sum_{n=1}^N r_{nk} T(x_n)}{N_k}$$

Esto implica que $\frac{\partial A(\eta_k)}{\partial \eta_k}$ es monótona e invertible, por lo que:

$$\boxed{\eta_k^* = \left(\frac{\partial A(\eta_k)}{\partial \eta_k} \right)^{-1} \left(\frac{\sum_{n=1}^N r_{nk} T(x_n)}{N_k} \right)}$$

Esto permite solo calcular los parámetros en cada iteración de EM, en lugar de tener que hacer una optimización de $\mathcal{Q}$ en cada paso.

Al final del algoritmo, obtendremos:

$$\theta^* = \{\pi_k, \mu_k, \Sigma_k\} \quad \text{y} \quad r_{nk}$$

Y podremos saber con qué certeza proviene cada muestra x_n a la gaussiana k :

$$k^*(x_n) = \arg \max_k r_{nk}$$

De no existir esta solución analítica cerrada, no tendríamos garantía de convergencia monótona ([4] Wainwright, M. J., & Jordan, M. I. (2008)).

Referencias:

- La referencia principal e imprescindible para esta parte es [3] Bishop, C. M. (2006). El capítulo 9 cubre prácticamente todo.
- Para la conexión con la familia exponencial, [4] Wainwright, M. J., & Jordan, M. I. (2008), cubre en profundidad por qué la familia exponencial hace tratable el paso M y la propiedad de que $\frac{dA}{d\eta}$ es invertible.
- Para la derivación del ELBO y algunos de los resultados teóricos en relación con el algoritmo EM [5] Neal, R. M., & Hinton, G. E. (1998).
- Como complemento más accesible, [6] Murphy, K. P. (2022).